

Guía Metodológica Avanzada para la Formulación Inicial: Planteamiento, Hipótesis, Preguntas, Objetivos y Antecedentes

Prof. D. Sierra-Porta

Universidad Tecnológica de Bolívar

Escuela de Transformación Digital — Programa de Ciencia de Datos

Asignatura: Proyecto de Grado I

El presente documento detalla y profundiza en el núcleo metodológico fundamental que los estudiantes deben consolidar, argumentar y defender rigurosamente durante la etapa de Proyecto de Grado I. Una formulación inicial sólida, coherente y estructurada constituye el cimiento indispensable que determina la viabilidad técnica, el rigor científico y el éxito analítico de todo el proceso de investigación y desarrollo posterior.

1. El Planteamiento del Problema: La Metodología del Embudo Analítico

1.1 Estructura metodológica en capas progresivas

Un planteamiento de problema profesional y riguroso en el campo de la ciencia de datos nunca debe redactarse bajo la estructura de un ensayo reflexivo libre o una narrativa descriptiva superficial. Por el contrario, debe concebirse estrictamente como un **embudo analítico** que conduce de manera sistemática al lector desde un escenario macroscópico general hasta el vacío técnico y específico que el proyecto se propone resolver:

- **Nivel macro (Contexto global, industrial o sectorial):** Caracterización amplia del fenómeno de estudio a escala macroeconómica, industrial o social. Se describen las tendencias generales, los retos globales o las ineficiencias sistémicas que afectan a un sector determinado (p. ej., las crecientes ineficiencias logísticas, el incremento de la congestión y los desafíos críticos de movilidad urbana en ciudades intermedias).
- **Nivel mesosistema (Escenario local, operacional y disponibilidad de datos):** Delimitación estricta de la manifestación concreta del problema en el entorno geográfico, institucional u operativo específico donde el investigador cuenta con acceso real a fuentes de información (p. ej., el análisis pormenorizado de los cuellos de botella viales específicos, los patrones de transporte público y el estado actual de la infraestructura de registros de tráfico en la ciudad de Cartagena de Indias).
- **La brecha analítica o técnica (The Gap):** Identificación precisa, quirúrgica y fundamentada del vacío exacto que la literatura científica previa, los reportes técnicos y los sistemas actuales implementados no han logrado resolver de manera satisfactoria (p. ej., la ausencia absoluta de modelos predictivos locales capaces de integrar de forma dinámica y simultánea variables meteorológicas de alta resolución y flujos vehiculares en tiempo real para optimizar corredores viales críticos).

1.2 Criterio estricto de validación y control del problema

Para comprobar la solidez, pertinencia y acotación del planteamiento formulado, se recomienda

aplicar una rigurosa prueba de control lógico: si se eliminan en su totalidad los párrafos introductorios de ambientación general, el texto resultante debe evidenciar de manera inmediata, unívoca e ineludible qué datos específicos faltan, qué proceso operativo es ineficiente o qué patrón oculto no ha sido caracterizado correctamente en la región o sistema objeto de estudio.

2. Pregunta de Investigación y su Alineación Estricta con el Objetivo General

2.1 Especificidad, acotación y operatividad de la pregunta

La pregunta de investigación constituye el eje gravitacional, el núcleo rector y la brújula de todo el proyecto de grado. Por consiguiente, debe formularse de manera altamente acotada, eludiendo por completo ambigüedades filosóficas, reflexivas o especulativas, y orientándose de forma estricta hacia una acción analítica perfectamente medible y contrastable.

Ejemplo de formulación operativa óptima:

¿En qué medida la incorporación de variables meteorológicas de alta frecuencia en un modelo predictivo basado en LightGBM reduce el error cuadrático medio (RMSE) en la predicción de flujos vehiculares a corto plazo en Cartagena de Indias, en comparación con un modelo autorregresivo clásico de línea base?

2.2 El principio de coherencia unívoca y simetría estructural

Existe una correspondencia formal, matemática y lógica directa e inexcusable entre la estructura gramatical y conceptual de la pregunta de investigación y la formulación del objetivo general del proyecto:

- **Pregunta de investigación $\rightarrow$** Delimita con absoluta precisión la relación causal, la estructura del patrón analítico o la naturaleza exacta del artefacto computacional o de datos que se construirá.
- **Objetivo general $\rightarrow$** Adopta imperativamente un verbo en infinitivo de alta categoría taxonómica que responda de forma directa, unívoca y simétrica a los componentes planteados en la pregunta (p. ej., si la pregunta indaga por la reducción del error mediante un modelo, el objetivo general debe iniciar con verbos tales como *Desarrollar, Evaluar, Diseñar y validar...*).

3. Hipótesis de Trabajo frente a Preguntas Orientadoras en Ciencia de Datos

Representa un error metodológico conceptual muy frecuente asumir de antemano que todo proyecto de ciencia de datos requiere obligatoriamente la formulación de una hipótesis formal. La obligatoriedad de la hipótesis depende estrictamente de la naturaleza y el alcance

metodológico del estudio:

3.1 Cuándo formular obligatoriamente una Hipótesis formal

Las hipótesis de trabajo se reservan de manera exclusiva para proyectos de carácter **explicativo, correlacional o de evaluación comparativa de rendimiento** (p. ej., la validación formal de un nuevo pipeline predictivo, la optimización sistemática de arquitecturas neuronales o la ejecución de pruebas estadísticas formales de significancia para comprobar la superioridad de un algoritmo frente a otro).

Estructura recomendada y formalizada:

"La implementación de [Técnica / Variable predictiva A] sobre el conjunto de datos [Dataset B] optimiza en al menos un [X%] la métrica de desempeño [Métrica C] en comparación con el modelo de referencia o línea base [Baseline D]".

3.2 Cuándo emplear Preguntas Orientadoras o Criterios de Diseño

Se deben aplicar ineludiblemente en proyectos cuya naturaleza sea de carácter **exploratorio, descriptivo o de arquitectura de sistemas y productos de datos** (p. ej., el diseño conceptual e implementación de un sistema de información analítico, la construcción de una taxonomía de datos geoespaciales o la caracterización estadística exploratoria inicial de un fenómeno donde no se busca contrastar una causalidad estadística previa, sino evaluar la viabilidad estructural, la escalabilidad y el comportamiento operativo de un artefacto analítico).

4. Los Objetivos Específicos como Hitos del Ciclo de Vida Analítico (CRISP-DM)

En el riguroso ámbito de la ciencia de datos, los objetivos específicos jamás deben plantearse como meras actividades académicas pasivas o de carácter contemplativo (tales como "estudiar", "comprender", "conocer" o "analizar bibliografía"). Deben concebirse estrictamente como hitos operacionales cuantificables y secuenciales, estructurados de manera natural bajo marcos formales de procesos analíticos internacionalmente reconocidos como CRISP-DM (Cross-Industry Standard Process for Data Mining):

1. **Fase de Adquisición e Ingeniería de Datos:** Recolectar, limpiar, integrar, transformar y estructurar formalmente las fuentes de datos primarias o secundarias requeridas, garantizando la calidad y consistencia necesarias para el análisis.
2. **Fase de Análisis Exploratorio y Caracterización:** Identificar, visualizar y cuantificar patrones espaciales, temporales, dependencias estadísticas, correlaciones complejas o anomalías presentes en el conjunto de datos procesado.
3. **Fase de Modelado y Desarrollo Analítico:** Diseñar, entrenar, calibrar, ajustar hiperparámetros e implementar la solución algorítmica, el modelo predictivo o el sistema analítico propuesto.
4. **Fase de Validación y Evaluación de Desempeño:** Evaluar de forma objetiva, rigurosa y contrastada el desempeño operativo y estadístico del modelo o artefacto desarrollado frente

a las métricas de éxito preestablecidas y las líneas base de comparación.

5. Construcción de Antecedentes Orientados a Métodos, Datos y Vacíos

Los antecedentes bibliográficos y del estado del arte nunca deben constituirse como un listado cronológico pasivo de resúmenes aislados de artículos científicos. Cada sección temática debe consolidarse mediante una matriz analítica estructurada que permita evidenciar de manera inequívoca e irrefutable el vacío analítico, metodológico o de datos que el proyecto actual se dispone a resolver:

Autor / Año	Fuente de Datos / Alcance Geográfico	Técnica / Algoritmo Empleado	Métrica de Desempeño Obtenida	Limitación / Vacío que el Proyecto Aborda
[Autor, A. et al., Año] <i>[Título abreviado del trabajo previo]</i>	[Descripción precisa de la fuente, volumen de datos, resolución temporal y espacial, y periodo evaluado].	[Especificación detallada del modelo, algoritmo, heurística o marco metodológico utilizado].	[Valor cuantitativo de la métrica de éxito o error reportada en el estudio previo].	[Identificación explícita de la carencia metodológica, ausencia de variables o limitación regional que subsiste].
[Autor, B. & Autor, C., Año] <i>[Título abreviado del trabajo previo]</i>	[Descripción precisa de la fuente, volumen de datos, resolución temporal y espacial, y periodo evaluado].	[Especificación detallada del modelo, algoritmo, heurística o marco metodológico utilizado].	[Valor cuantitativo de la métrica de éxito o error reportada en el estudio previo].	[Identificación explícita de la carencia metodológica, ausencia de variables o limitación regional que subsiste].