UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR

ESCUELA DE TRANSFORMACIÓN DIGITAL

PROGRAMA DE CIENCIA DE DATOS

GUÍA METODOLÓGICA Y LINEAMIENTOS INTEGRALES PARA LA ELABORACIÓN DEL ANTEPROYECTO DE TRABAJO DE GRADO

PRESENTACIÓN INSTITUCIONAL Y PROPÓSITO DE LA GUÍA

El presente documento constituye la directriz oficial y el marco normativo, para los estudiantes y docentes del programa de **Ciencia de Datos**, adscrito a la **Escuela de Transformación Digital de la Universidad Tecnológica de Bolívar (UTB)**. Su propósito fundamental es estandarizar, orientar y elevar el rigor técnico, metodológico, científico y ético en el diseño y formulación del anteproyecto de trabajo de grado (también denominado protocolo o propuesta de investigación y desarrollo).

La ciencia de datos se posiciona como una disciplina convergente que articula los fundamentos rigurosos de la estadística, las matemáticas aplicadas, la computación de alto rendimiento y la ingeniería de software con la resolución de retos complejos en los sectores socioeconómicos, industriales y científicos. En consecuencia, un anteproyecto en este campo no puede limitarse a una revisión teórica o a la aplicación acrítica de librerías informáticas; debe evidenciar una sólida formulación del problema, un diseño metodológico reproducible, una gestión transparente de los datos y un estricto cumplimiento de los principios éticos y de gobernanza de la información.

Las directrices aquí descritas son de obligatorio cumplimiento para la presentación de propuestas de grado en el programa. No obstante, fomentan la creatividad analítica y la innovación tecnológica bajo los estándares de calidad exigidos por la Universidad Tecnológica de Bolívar y la comunidad científica internacional.

---

1. ESTRUCTURA GENERAL Y CAPITULADO DEL ANTEPROYECTO

El documento escrito del anteproyecto de trabajo de grado de Ciencia de Datos deberá organizarse de manera secuencial y coherente respetando la siguiente estructura formal:

Portada institucional (ajustada a los lineamientos visuales y formales de la UTB).

Tabla de Contenido (incluyendo índices específicos de tablas y figuras).

Resumen / Abstract (síntesis del proyecto con palabras clave y *keywords*).

1. Introducción y Contextualización

2. Planteamiento del Problema de Ciencia de Datos

3. Justificación, Relevancia y Viabilidad

4. Objetivos (General y Específicos)

5. Marco de Referencia y Estado del Arte

6. Diseño Metodológico y Arquitectura de la Solución (Pipeline Analítico)

7. Gestión de Datos, Infraestructura Tecnológica y Reproducibilidad

8. Consideraciones Éticas, Sesgo, Privacidad y Gobernanza de Datos

9. Cronograma de Actividades

10. Recursos, Presupuesto y Viabilidad Operativa

11. Referencias Bibliográficas (Bajo normativa IEEE)

12. Anexos y Documentación de Soporte

2. DESARROLLO DETALLADO DE LOS APARTADOS DEL ANTEPROYECTO

2.1. PORTADA

La portada debe reflejar la identidad institucional de la Universidad Tecnológica de Bolívar y de la Escuela de Transformación Digital. Contendrá de manera clara: el escudo oficial de la universidad, el nombre de la institución, la facultad o escuela, el programa académico de Ciencia de Datos, el título completo y preciso del proyecto de grado, el nombre del estudiante o autores, el nombre del director (y codirector o asesores si aplica), la ciudad (Cartagena de Indias, D. T. y C.) y la fecha de presentación.

2.2. INTRODUCCIÓN

La introducción actúa como la ventana de presentación del anteproyecto. Debe redactarse de forma fluida y persuasiva, permitiendo que cualquier evaluador se familiarice rápidamente con el núcleo de la investigación sin requerir lecturas previas externas. Debe integrar de manera discursiva:

- La naturaleza y el dominio de aplicación del problema (ej. optimización logística, modelado climático, salud pública, procesamiento de lenguaje natural aplicado, entre otros).
- Una visión panorámica del enfoque analítico seleccionado.
- Las motivaciones técnicas, científicas o prácticas que impulsaron la propuesta.
- Los resultados genéricos esperados y los alcances espaciales y temporales previstos.

2.3. PLANTEAMIENTO DEL PROBLEMA DE CIENCIA DE DATOS

El planteamiento del problema es el eje central sobre el cual gravita toda la propuesta. En el ámbito de la ciencia de datos, no basta con describir un fenómeno social o industrial; es indispensable formular el problema en términos analíticos y de datos. Este apartado debe detallar:

- **La brecha de conocimiento o deficiencia operativa:** ¿Qué decisiones se están tomando bajo incertidumbre o qué ineficiencias existen por la falta de modelos predictivos, prescriptivos o descriptivos?
- **La naturaleza de los datos:** ¿Qué fuentes de datos existen, cuáles son sus limitaciones (volumen, velocidad, variedad, veracidad, sesgos históricos, valores perdidos o ruido) y cómo se planea superar dicha escasez o complejidad?
- **Preguntas de investigación o hipótesis analíticas:** El problema debe desembocar en interrogantes claros o hipótesis contrastables que guiarán el desarrollo del modelo o análisis. Se aconseja respaldar la magnitud del problema mediante gráficos, diagramas de flujo de datos, estadísticas descriptivas preliminares o evidencias empíricas.

2.4. Justificación y Viabilidad

Este apartado constituye la argumentación de valor del anteproyecto ("propuesta de valor científico y técnico"). Debe argumentar sólidamente:

- **Relevancia teórica y práctica:** Cómo el desarrollo del proyecto contribuye al avance de las metodologías de ciencia de datos o resuelve un problema real del contexto regional, nacional o global.
- **Impacto esperado:** Beneficiarios directos e indirectos, valor económico, social o ambiental de los resultados.
- **Viabilidad técnica y operativa:** Demostración de que se cuenta con el acceso a las fuentes de datos, el dominio teórico de los algoritmos y la capacidad computacional o infraestructura requerida para culminar el proyecto con éxito dentro del plazo estipulado.

2.5. Objetivos

- **Objetivo General:** Define la meta terminal y el propósito central del trabajo de grado. Debe responder inequívocamente al *qué* se va a hacer, *cómo* se abordará analíticamente y *para qué*. Se redacta obligatoriamente iniciando con un verbo en infinitivo de alto nivel cognitivo (ej. *Desarrollar, Diseñar, Implementar, Evaluar, Modelar, Comparar*). Debe guardar total coherencia con el título y el problema planteado.
- **Objetivos Específicos:** Desglosan las etapas tácticas y secuenciales necesarias para alcanzar el objetivo general. Representan los hitos metodológicos del proyecto (ej. recolectar y preprocesar el corpus de datos, realizar el análisis exploratorio y de ingeniería de características, entrenar y optimizar los algoritmos de aprendizaje automático, y evaluar el desempeño del modelo final bajo métricas estándar).

2.6. Marco de Referencia y Estado del Arte

El marco de referencia no es un compendio enciclopédico de conceptos generales, sino una revisión crítica, actualizada y rigurosa de la literatura científica y técnica. Debe estructurarse en:

- **Fundamentación Teórica y Matemática:** Descripción formal de los modelos estadísticos, arquitecturas de redes neuronales, algoritmos de aprendizaje supervisado/no supervisado o técnicas de procesamiento empleadas.
- **Estado del Arte:** Análisis comparativo de trabajos de investigación recientes (preferiblemente de los últimos 5 años en revistas indexadas o conferencias de alto impacto). Se debe establecer un diálogo crítico entre los autores, identificando qué métricas lograron, qué limitaciones metodológicas presentaron y cómo la propuesta actual supera o complementa dichos vacíos.

2.7. Diseño Metodológico y Arquitectura de la Solución (Pipeline Analítico)

La metodología en ciencia de datos se describe como un *pipeline* o ciclo de vida estructurado (adaptando marcos de referencia reconocidos como CRISP-DM u OSEMN). Debe detallar paso a paso:

1. **Adquisición y Extracción:** Definición de repositorios, bases de datos, APIs o sensores de donde se obtendrán los datos crudos (*raw data*).
2. **Preprocesamiento y Limpieza:** Estrategias para el tratamiento de valores atípicos (*outliers*), imputación de datos faltantes, normalización, estandarización y codificación de variables categóricas.
3. **Ingeniería de Características (*Feature Engineering*):** Criterios de selección, transformación, reducción de dimensionalidad (ej. PCA) y creación de nuevas variables explicativas.
4. **Modelado y Experimentación:** Justificación en la selección de los algoritmos (ej. Random Forest, Gradient Boosting, Redes Neuronales Profundas, Modelos de Series de Tiempo, etc.), diseño de particionamiento de datos (entrenamiento, validación y prueba) y estrategias de validación cruzada (*cross-validation*).

5. **Métricas de Evaluación:** Selección rigurosa de los indicadores de desempeño cuantitativos adecuados al problema (ej. Accuracy, Precision, Recall, F1-Score, ROC-AUC para clasificación; MSE, RMSE, MAE, R^2 para regresión; métricas de negocio asociadas).

2.8. Gestión de Datos, Infraestructura Tecnológica y Reproducibilidad

Para garantizar los estándares modernos de ingeniería de datos y reproducibilidad científica en la UTB, este apartado es obligatorio y debe estipular:

- **Control de Versiones y Repositorio:** Obligatoriedad de utilizar un sistema de control de versiones (ej. GitHub), especificando la estructura del repositorio, la documentación en archivos `README.md` y la gestión de dependencias (`requirements.txt`, `pyproject.toml` o entornos virtuales).
- **Almacenamiento y Versionamiento de Datos:** Especificación de cómo se gestionarán los conjuntos de datos, asegurando que los datos sensibles sean anonimizados o que se utilicen esquemas de almacenamiento seguros (bases de datos relacionales, no relacionales o *data lakes*).
- **Reproducibilidad Experimental:** Declaración de las estrategias para asegurar la replicabilidad de los resultados (fijación de semillas aleatorias en los scripts, uso de contenedores como **Docker** o cuadernos Jupyter limpios y ejecutables de forma secuencial).

2.9. Consideraciones Éticas, Sesgo, Privacidad y Gobernanza de Datos

Dado el profundo impacto social y tecnológico de los sistemas basados en datos e inteligencia artificial, el anteproyecto debe contemplar un acápite ético que aborde:

- **Privacidad y Protección de Datos:** Cumplimiento de marcos legales y éticos sobre el tratamiento de datos personales e institucionales (anonimización, cifrado, consentimiento informado si aplica).
- **Mitigación de Sesgos:** Identificación de posibles sesgos en los datos históricos de entrenamiento que puedan perpetuar discriminaciones o generar inequidades algorítmicas, proponiendo mecanismos de auditoría o equidad (*fairness*).
- **Declaración de Uso de Herramientas de Inteligencia Artificial:** Si el estudiante empleó asistentes basados en Inteligencia Artificial Generativa (LLMs) para tareas de apoyo en la conceptualización, depuración de código, traducción o estructuración del documento, **deberá declarar explícitamente** qué herramientas utilizó, en qué fases del proyecto y con qué propósito exacto, garantizando en todo momento la autoría intelectual y la validación experta de los resultados.

2.10. Cronograma de Actividades

Debe incluirse una representación gráfica (como un diagrama de Gantt) que desglose temporalmente las actividades del proyecto, organizadas por semanas o meses, desde la formulación del anteproyecto hasta la sustentación final ante jurados, contemplando hitos de entrega de avances y revisión de informes.

2.11. Recursos, Presupuesto y Viabilidad Operativa

Listado pormenorizado de los recursos requeridos para la ejecución exitosa del proyecto, clasificados en:

- **Recursos Humanos:** Estudiante investigador, director, asesores temáticos o estadísticos.
- **Recursos de Hardware y Software:** Computo de altas prestaciones, licencias de software especializado, servicios en la nube (ej. AWS, Google Cloud, Colab Pro) o librerías de código abierto.

- **Presupuesto Estimado:** Costos asociados al desarrollo del trabajo de grado.

3. NORMAS DE CITACIÓN Y REFERENCIAS BIBLIOGRAFÍCAS (ESTILO IEEE)

Para mantener la congruencia con las publicaciones de ingeniería y ciencias de la computación, el programa de Ciencia de Datos adopta el **estilo de citación y referencias IEEE**.

3.1. Citas en el Texto

- Las referencias dentro del cuerpo del texto se indican mediante números arábigos consecutivos encerrados entre corchetes cuadrados (ej. *"...como se ha demostrado en la literatura reciente [1], [2]."* o *"Smith y colaboradores [3] proponen una arquitectura basada en..."*).
- Si se hace mención directa al autor, el número se coloca inmediatamente después del nombre o al final de la proposición.
- Las citas textuales cortas o paráfrasis deben ir acompañadas obligatoriamente de su respectivo corchete numérico.

3.2. Lista de Referencias

- La lista final de referencias debe ubicarse al final del documento, ordenada estrictamente en orden numérico creciente según su **primer orden de aparición** en el texto (no por orden alfabético).
- **Ejemplos normativos IEEE:**
    - **Artículo de revista científica (Journal):** [1] J. K. Author, "Title of the paper," *Abbreviated Title of Periodical*, vol. x, no. x, pp. xxx-xxx, Abbreviated Month, Year.
    - **Libro o texto académico:** [2] M. Smith, *Introduction to Machine Learning*, 2nd ed. City, State: Publisher, Year.
    - **Ponencia en Conferencia:** [3] A. B. Researcher and C. D. Author, "Title of conference paper," in *Name of Conference*, City, Country, Year, pp. xx-xx.
    - **Repositorios de Código o Recursos Web:** [4] A. Creator. "Title of repository or web page." GitHub repository. Available: https://github.com [Accessed: Month Day, Year].

4. FORMATO DE PRESENTACIÓN Y ESTILO DEL DOCUMENTO ESCRITO

Para la entrega oficial del anteproyecto ante el comité evaluador de la Escuela de Transformación Digital, el documento escrito debe ajustarse rigurosamente a las siguientes especificaciones formales:

1. **Tipografía:** Fuente **Arial**, tamaño **12 puntos** para el cuerpo de texto principal. Los títulos de capítulos principales deben ir en negrita y tamaño 14 o 12 según jerarquía; los subtítulos en negrita y tamaño 12.
2. **Interlineado y Alineación:** El interlineado del texto principal debe ser de **1.5 líneas**, con alineación **justificada**. Entre párrafos se debe dejar un espacio o interlineado adicional automático.
3. **Márgenes:** Márgenes perimetrales uniformes de **2.54 cm** (1 pulgada) en todos los lados de la hoja (tamaño carta / Letter).
4. **Paginación:** Todas las páginas deben numerarse en el extremo inferior derecho o inferior exterior, exceptuando la página de la portada (la cual se cuenta de forma tácita pero no lleva número impreso). Las páginas preliminares pueden usar numeración romana en minúsculas y el cuerpo principal numeración arábiga.

5. **Tablas y Figuras:** Deben numerarse de forma secuencial e independiente (ej. *Figura 1. Diagrama del pipeline de datos*, *Tabla 1. Comparativa de métricas de desempeño*). Las tablas llevan su título y número en la parte superior; las figuras, gráficos de modelos, diagramas de arquitectura o capturas muestran su título y fuente en la parte inferior, indicando siempre la autoría o procedencia de los datos.

6. **Encabezado y Pie de Página (Footer):** En el pie de página se incluirá una línea continua fina separando el texto principal y, alineado de manera discreta, el título abreviado del anteproyecto en letras mayúsculas, negrita, fuente Arial de 9 puntos en color gris oscuro.

Documento institucional de referencia metodológica para el programa de Ciencia de Datos — Escuela de Transformación Digital — Universidad Tecnológica de Bolívar.